



CURSO DATA ENGINEERING

EVALUACIÓN:

Diseño e Implementación de ETL y Esquema Estrella: Análisis de Consumo de Snacks –
Mundial 2026 (Guatemala)

ESTUDIANTES:

-LUIS ESCOBAR

-EDWIN FERNANDEZ

-GERARDO QUINTANILLA

-GERARDO CARRANZA

CATEDRÁTICO:

INGENIERO DIEGO ALBERTO MÉNDEZ

Introducción

El presente informe detalla el proceso de extracción, transformación y carga (ETL) realizado sobre los datos obtenidos de la "Encuesta de Snacks Mundial 2026" aplicada a 2,500 consumidores en Guatemala. Ante la llegada del evento deportivo más grande del mundo, comprender los hábitos de consumo, preferencias de sabores, disposición de gasto y la influencia de campañas publicitarias es crucial para la toma de decisiones estratégicas de negocio.

Para lograrlo, se procesó un conjunto de datos en bruto y se estructuró mediante un modelado dimensional tipo **Esquema Estrella (Star Schema)**. Este diseño optimiza las consultas analíticas, separando las métricas cuantitativas (tabla de hechos) de sus atributos descriptivos (tablas de dimensiones), permitiendo así generar reportes empresariales que revelan el perfil demográfico, la frecuencia de consumo y el impacto de la publicidad en la intención de compra.

Objetivos

Objetivo General

- Diseñar e implementar un flujo de procesamiento de datos (ETL) y un modelo dimensional en esquema estrella para analizar los patrones de consumo de snacks en Guatemala en el contexto del Mundial 2026.

Objetivos Específicos

1. **Auditar y limpiar** el conjunto de datos original, gestionando valores nulos, registros duplicados e inconsistencias tipográficas.
2. **Transformar** los datos mediante la creación de nuevas variables de valor comercial (segmentación de edad, categorización de precios e indicadores de intención de compra).
3. **Construir un Esquema Estrella** que centralice las métricas en una tabla de hechos (**fact_encuesta**) conectada a cinco dimensiones clave: encuestado, ubicación, tiempo, snack y campaña.
4. **Generar reportes analíticos** que faciliten la identificación del público objetivo, los productos estrella y los medios publicitarios más efectivos.

4. Metodología

El proyecto se desarrolló bajo un enfoque de **Desarrollo Ágil para Data Analytics**, estructurando un flujo de trabajo de Extracción, Transformación y Carga (ETL) diseñado para procesar datos en bruto y convertirlos en un activo de información estratégica. Todo el pipeline de datos fue programado en el lenguaje **Python**, utilizando la librería **Pandas** como motor principal de procesamiento vectorial por su alta eficiencia en el manejo de estructuras de datos bidimensionales (*DataFrames*).

La metodología implementada siguió rigurosamente las siguientes etapas:

1. **Extracción y Auditoría Defensiva:** Se optó por una primera lectura en crudo utilizando la librería estándar `csv.DictReader` de Python. Esta técnica permitió inspeccionar el archivo ignorando las inferencias automáticas de Pandas, lo que garantizó una detección precisa de valores nulos reales y saltos de línea anómalos antes de cargar el modelo en memoria.
2. **Data Cleansing (Limpieza de Datos):** Aplicación de técnicas de estandarización morfológica, deduplicación algorítmica e imputación de valores faltantes para asegurar la integridad referencial y semántica del conjunto de datos.
3. **Feature Engineering (Ingeniería de Características):** Creación de variables derivadas (métricas de negocio) a partir de los datos limpios para enriquecer la capacidad analítica del modelo.
4. **Modelado Dimensional (Esquema Estrella):** Diseño de la arquitectura de datos bajo los principios de Ralph Kimball, separando la información en una tabla de hechos (*Fact Table*) y múltiples tablas de dimensiones (*Dimension Tables*) para optimizar el rendimiento de las consultas y la conexión con herramientas de visualización (Dashboards).
5. **Analítica Descriptiva:** Generación de resúmenes estadísticos cruzados (`pd.crosstab`, `groupby`) para responder a las preguntas de negocio planteadas.

5. Limpieza de Datos (Data Cleansing)

La calidad de los datos es el pilar fundamental de cualquier análisis. Durante la auditoría inicial de las 2,500 respuestas, se identificaron anomalías estructurales y semánticas que fueron corregidas mediante un pipeline de limpieza sistemático:

- **Estandarización de Cadenas (Trimming):** Los datos provenientes de encuestas suelen contener espacios en blanco accidentales. Se aplicó una iteración de limpieza (`str.strip()`) sobre todas las columnas para evitar que, por ejemplo, "Queso " y "Queso" fueran interpretados como categorías distintas por el motor analítico.
- **Integridad Referencial (Deduplicación):** Se detectaron registros duplicados. Utilizando la función `drop_duplicates(subset="EncuestaID")`, se garantizó la unicidad de cada encuestado conservando la primera ocurrencia (`keep="first"`), asegurando que ninguna respuesta tuviera un peso doble en los resultados estadísticos.
- **Normalización Tipográfica:** Variables de alta importancia comercial como *SaborPreferido* presentaban ruido tipográfico (mezcla de mayúsculas, minúsculas y valores residuales como "nan" en formato texto). Se aplicó una normalización a formato de título (`str.title()`) y reemplazo directo para unificar las categorías.
- **Estrategias de Imputación de Vacíos:** Los valores nulos (missing values) no se eliminaron para no perder la significancia estadística de la muestra; en su lugar, se aplicaron dos criterios de imputación según la naturaleza de la variable:
 - **Imputación Determinística:** En variables de texto libre (como *Municipio* u *Ocupacion*), se rellenaron los vacíos con la etiqueta "No especificado" para mantener la trazabilidad.
 - **Imputación Estadística (Moda):** En variables categóricas cerradas de alto impacto (como *PrecioAdecuado* y *SaborPreferido*), se calculó la medida de tendencia central más representativa (la moda, mediante `value_counts().idxmax()`) y se imputó este valor a los registros vacíos, minimizando la distorsión de la distribución original.
- **Casteo de Tipos (Type Casting):** Se optimizó la memoria y se habilitaron operaciones lógicas convirtiendo explícitamente los identificadores a enteros (`int`) y parseando las cadenas de fecha/hora al formato nativo `datetime` de Pandas.

Transformaciones (Feature Engineering) y Modelado Dimensional

Una vez asegurada la calidad del dato, se procedió a la fase de transformación para traducir los datos operativos en verdaderos indicadores de negocio (*KPIs*) y estructurarlos para el consumo analítico.

6.1. Creación de Variables Derivadas

Para responder directamente a los objetivos de la campaña del Mundial 2026, se desarrollaron nuevas columnas calculadas:

- **Mapeo de Segmentos de Mercado:** Mediante diccionarios de conversión técnica (`.map()`), los rangos continuos de edad se transformaron en segmentos comerciales (Ej. "18 - 24 años" a "Joven Adulto") y los rangos de precio a categorías de posicionamiento ("Accesible", "Premium"). Esto facilita la lectura ejecutiva en el dashboard final.
- **Atomización de Arreglos Múltiples:** La columna *SnacksSeleccionados* contenía múltiples valores agrupados y separados por punto y coma. Mediante funciones lambda (`lambda x: len(...)`), se logró aislar y contar la cantidad exacta de productos elegidos por cada consumidor, creando la variable cuantitativa `CantidadSnacks`.
- **Binarización de Intención de Compra:** La respuesta cualitativa sobre la disposición a pagar más por una edición del Mundial se transformó en un formato booleano/entero (`AltaIntencionCompra`: 1 para "Sí", 0 para "No"). Esta técnica es crucial porque permite calcular probabilidades promedio con simples operaciones aritméticas (Ej. `mean()`).

6.2. Diseño del Esquema Estrella (Star Schema)

Para finalizar la fase de transformación y preparar los datos para la herramienta de Business Intelligence, el *Dataframe* plano (`df_limpio`) fue normalizado y fragmentado en una arquitectura de Esquema Estrella. Este diseño relacional se compone de:

1. **Dimensiones Descriptivas:** Tablas estáticas que proveen el "quién, dónde, cuándo y cómo". Se crearon cinco dimensiones extrayendo valores únicos y asignando claves primarias:
 - `dim_encuestado`: Perfil del consumidor.
 - `dim_ubicacion`: Geografía departamental y municipal.
 - `dim_tiempo`: Extracción de mes, fecha y hora de la transacción.
 - `dim_campania`: Preferencias publicitarias.
 - `dim_snack`: Se aplicó la función avanzada `.explode()` sobre los snacks seleccionados para resolver la relación de "muchos a muchos", generando una fila única por cada tipo de snack asociado a un usuario, permitiendo un conteo exacto en el ranking general.

2. **Tabla de Hechos (*fact_encuesta*):** Es el núcleo del modelo. Esta tabla fue diseñada para ser lo más estrecha posible, almacenando únicamente las métricas cuantitativas (como el gasto y la intención de compra) y las claves foráneas (IDs) que la vinculan directamente con cada una de las tablas dimensionales.

7. Análisis, Resultados e Interpretación

El procesamiento de los datos modelados en el Esquema Estrella permitió ejecutar la analítica descriptiva de los primeros 6 indicadores clave. A continuación, se detallan los hallazgos cuantitativos y su respectiva interpretación de negocio:

Reporte 1: Perfil Demográfico

- **Resultados:** El mercado objetivo se concentra mayoritariamente (52.56%) en dos segmentos de edad: *Adulto Joven* (25 a 34 años, representando el 29.37%) y *Joven Adulto* (18 a 24 años, con un 23.19%). Además, la distribución por género en estos segmentos dominantes es sumamente equitativa (14.22% femenino frente a 14.42% masculino en el segmento principal).
- **Interpretación:** Nuestro *Buyer Persona* pertenece a las generaciones Millennial y Gen Z. Tienen poder adquisitivo propio o alta influencia en el gasto familiar. Al ser un mercado con paridad de género, la campaña publicitaria debe evitar los estereotipos clásicos que asocian el fútbol exclusivamente al público masculino, apostando por un tono inclusivo, dinámico y social.

Reporte 2: Frecuencia de Consumo y Elasticidad

- **Resultados:** Existe un hábito de consumo recurrente masivo. El 54.83% de los encuestados consume snacks con alta regularidad (27.92% lo hace de 1 a 2 veces por semana y 26.91% de 3 a 5 veces por semana). Además, el cruce de datos demostró que los consumidores de alta frecuencia tienen una probabilidad significativamente mayor de pagar un costo extra por ediciones especiales.
- **Interpretación:** El producto no es de compra esporádica, sino parte de la rutina semanal. Dado que el Mundial dura aproximadamente un mes, esta alta rotación representa una oportunidad perfecta para estrategias de fidelización y recompra. El cliente está dispuesto a invertir en su hábito si se le ofrece un valor agregado (como empaques coleccionables).

Reporte 3: Ranking de Snacks y Sabores

- **Resultados:** La preferencia de productos está liderada por los *Mundialitos Queso Picante* (27.72% de menciones), seguidos de cerca por *CrunchMax BBQ* (27.15%) y *Gol Nachos Supreme* (25.74%). En el análisis puro de paladar, el "Queso" domina el mercado, pero con una fuerte inclinación hacia el "Picante Chapín" y la "Barbacoa".
- **Interpretación:** El consumidor guatemalteco exige perfiles de sabor intensos y con anclaje cultural (Picante Chapín). Cualquier estrategia de posicionamiento debe priorizar las líneas de producto saladas/picantes, descartando por completo los sabores dulces o neutros para esta campaña.

Reporte 4: Análisis de Precios

- **Resultados:** El comportamiento de precio en la demanda está claramente definido en el rango medio. La categoría "Moderado" (Q16 - Q20) captura el 36.28% de la disposición de gasto, seguida de la categoría "Accesible" (Q10 - Q15) con un 29.66%. Las categorías extremas (Económico y Súper Premium) combinadas apenas superan el 13%.
- **Interpretación:** El mercado aprueba un aumento de precio por el "impuesto de Mundial" o de edición especial, pero dentro de un límite psicológico estricto (Q20 máximo). Si la empresa lanza un empaque coleccionable por debajo de Q16, estaría dejando dinero en la mesa. Si lo lanza por encima de Q20, perderá drásticamente el volumen de ventas necesario para que la campaña sea rentable.

Reporte 5: Equipos con Mayor Influencia

- **Resultados:** La lealtad del mercado guatemalteco hacia las selecciones extranjeras está liderada por **Argentina** (17.13% de la base), seguida de cerca por **Brasil** (14.46%) y, en tercer lugar, **México** (11.84%).
- **Interpretación:** Al no tener representación nacional en el evento, el consumidor adopta a las escuadras latinoamericanas más exitosas históricamente. La brecha a favor de Argentina frente a otras potencias europeas (como Francia o Portugal, ambas debajo del 10%) indica que la empatía regional y el arraigo cultural son factores de arrastre fortísimos.

Reporte 6: Jugadores con Mayor Influencia

- **Resultados:** La influencia deportiva está fuertemente polarizada. Lionel Messi lidera rotundamente con un 34.55% de menciones, seguido casi en empate técnico por Cristiano Ronaldo (32.44%). En un lejano tercer lugar se ubica Neymar Jr. (23.64%).
- **Interpretación:** El mercado del marketing deportivo en Guatemala se rige por la "idolatría personal" hacia superestrellas generacionales. La campaña debe apoyarse en la imagen de estos ídolos globales, ya que garantizan la atención de más del 65% del mercado de forma instantánea.

Reporte 7: Tipo de Publicidad Más Efectiva

- **Resultados:** El formato publicitario calificado como más atractivo por la audiencia fue "Un jugador famoso" (731 votos), el cual superó con amplia ventaja a formatos institucionales como "Una selección nacional" (614 votos) o tácticas de suerte como "Premios y sorteos" (469 votos).
- **Interpretación:** Este indicador confirma la tesis del Reporte 6. Para el consumidor, el rostro del atleta pesa más que la bandera de un país. La estrategia gráfica y visual en redes sociales, televisión y diseño de empaques debe centrarse en el "Héroe Deportivo" para maximizar la conversión.

Reporte 8: Promociones Preferidas

- **Resultados:** Las promociones que generan mayor incentivo son las de volumen y precio directo: el "2x1" (555 votos) y el "Descuento Directo" (542 votos). Como tercer factor de alto interés (414 votos) se ubicaron las "Tarjetas Coleccionables".
- **Interpretación:** El cliente busca una gratificación económica inmediata para justificar la compra. Sin embargo, el volumen sólido de interés en las tarjetas coleccionables abre la puerta a la "gamificación" (el impulso psicológico de completar una colección), lo cual es ideal para sostener las ventas a lo largo de las 4 semanas que dura el Mundial.

Reporte 9: Intención de Compra por Campaña

- **Resultados:** De todas las posibles iteraciones de producto evaluadas, la "Edición con jugadores famosos" fue catalogada como la que mayor intención de compra genera (16.89%). En segundo y tercer lugar hay casi un empate técnico entre una versión genérica ("Edición Mundial FIFA 2026" con 15.84%) y una versión temática de país ("Edición Argentina" con 15.64%).
- **Interpretación:** Esta métrica es el "Santo Grial" del análisis. Confirma irrefutablemente las tendencias observadas en los Reportes 6 y 7. El consumidor vota con su intención de gasto por las figuras individuales antes que por el evento en sí o por un país en particular (incluso siendo Argentina la selección más apoyada, la campaña con la imagen individual del jugador la superó).

8. Conclusiones y Recomendaciones Estratégicas

En función del proceso de Data Cleansing, las transformaciones y los indicadores generados hasta la fecha, se da respuesta a las principales preguntas de negocio planteadas por la dirección:

Recomendación Estratégica

La orquestación del proceso ETL, el modelo dimensional en Esquema Estrella y el panel de visualización (*Dashboard*) confirman un camino claro de comercialización.

Respuestas Definitivas a Preguntas de Negocio:

- **¿Qué snack debe promocionarse?** *Mundialitos Queso Picante y CrunchMax BBQ.*
- **¿Qué jugador debe utilizarse?** Lionel Messi (primer lugar) o Cristiano Ronaldo (casi empate estadístico).
- **¿Qué selección genera mayor influencia?** Argentina.
- **¿Qué promoción es más efectiva?** Ofertas de "2x1" o "Descuento directo".

- **¿Cuál es el rango de precio ideal?** Categoría Moderada (Q16 a Q20, siendo Q18 el punto de equilibrio sugerido).

Propuesta Comercial Ejecutiva: Lanzamiento "Ídolos del Sabor"

Se recomienda a la gerencia aprobar el rediseño temporal de la bolsa *Mundialitos Queso Picante*. El costo de venta al público en *retail* y supermercados (donde asisten predominantemente los segmentos *Adulto Joven* y *Joven Adulto*) debe fijarse en Q18.

La estrategia de empaque y marketing:

1. **La Cara Principal (El Gancho):** El frente del empaque debe ceder espacio protagónico a la fotografía de Lionel Messi o Cristiano Ronaldo. El logotipo del Mundial debe ser secundario.
2. **Los Colores:** Aunque Messi es el favorito individual, los tonos del empaque pueden evocar sutilmente la identidad gráfica de Argentina (Celeste/Blanco) para capturar el 17.13% de *Brand Love* nacional que tiene ese equipo.
3. **El Cierre de Venta (Promoción):** Las bandas promocionales del paquete deben ofrecer una dinámica coleccionable en su interior, pero en el piso de venta (góndola) debe existir una activación agresiva de "2x1" para incentivar la compra por impulso los fines de semana, momento donde el 54% de los consumidores realiza sus compras para ver los partidos en grupo.

Conclusión General

El presente proyecto integrador ha demostrado de manera contundente cómo la aplicación rigurosa de metodologías de Ingeniería de Datos (Data Engineering) e Inteligencia de Negocios (Business Intelligence) es capaz de transformar un conjunto de datos crudos en un activo estratégico de alto valor para la toma de decisiones. A través del análisis de la "Encuesta de Snacks Mundial 2026", se logró trazar un puente perfecto entre el procesamiento técnico de la información y la ejecución de una estrategia comercial real para el mercado guatemalteco.

A nivel técnico, el flujo de trabajo de Extracción, Transformación y Carga (ETL) desarrollado en Python y Pandas comprobó la importancia crítica de la calidad del dato (Data Cleansing). La detección de anomalías, la normalización tipográfica, la deduplicación de registros y la imputación estadística de vacíos garantizaron que los resultados finales no estuvieran sesgados. Más aún, la fase de Ingeniería de Características (Feature Engineering) —donde se crearon variables derivadas como segmentos de edad, categorías de precios e indicadores booleanos de intención de compra— permitió traducir datos operativos en verdaderos Indicadores Clave de Rendimiento (KPIs) comprensibles para la alta gerencia.

Desde la perspectiva arquitectónica, el diseño e implementación del modelo dimensional bajo un Esquema Estrella (Star Schema) resultó ser la decisión metodológica más acertada. Al centralizar las métricas cuantitativas en la tabla de hechos (**fact_encuesta**) y aislar los atributos descriptivos en sus respectivas dimensiones (encuestado, ubicación, tiempo, snack y campaña), se optimizó el rendimiento analítico, permitiendo cruzar variables complejas y generar los nueve reportes empresariales exigidos con precisión y eficiencia.

A nivel estratégico y de mercado, los datos revelaron hallazgos invaluable sobre el consumidor guatemalteco frente al Mundial FIFA 2026. Se identificó un *Buyer Persona* claramente definido:

jóvenes y adultos jóvenes (18 a 34 años) con un hábito de consumo de snacks altamente recurrente (varias veces por semana). En cuanto al paladar, los datos eliminaron cualquier ambigüedad, posicionando a los sabores intensos ("Queso" y "Picante Chapín") y a los productos estrella (*Mundialitos Queso Picante* y *CrunchMax BBQ*) como los motores fundamentales de ventas para esta temporada.

El análisis también derribó suposiciones tradicionales de marketing deportivo. Los datos comprobaron empíricamente que la idolatría hacia figuras individuales superestrellas (principalmente Lionel Messi y Cristiano Ronaldo) ejerce una influencia de compra muy superior a la empatía por las selecciones nacionales o la marca del Mundial en sí. Asimismo, el análisis de elasticidad de precios estableció una frontera psicológica clara: el mercado exige productos dentro de un rango "Moderado" (Q16 a Q20), demostrando que una campaña exitosa debe ser accesible para fomentar la alta rotación, en lugar de apostar por un bajo volumen de productos premium.

Finalmente, la integración de estos insights culminó en la sólida propuesta de la campaña **"Ídolos del Sabor"**. Esta recomendación no se basa en intuiciones, sino en evidencia matemática: maximiza la atracción visual mediante el uso de jugadores franquicia en el empaque, respeta la barrera del precio ideal (Q18), y asegura un retorno de inversión al combinar la urgencia económica ("Promociones 2x1") con la retención a mediano plazo ("Tarjetas Coleccionables").

